Нечеткая кластеризация потоков данных методом d-FuzzyStream

Поздняков Виталий

Высшая школа экономики

Декабрь 2019

Методология FOOF (Fuzzy Online-Offline Framework)

- Используется для работы с потоком данных
- Нечеткая версия OOF (Online-Offline Framework)

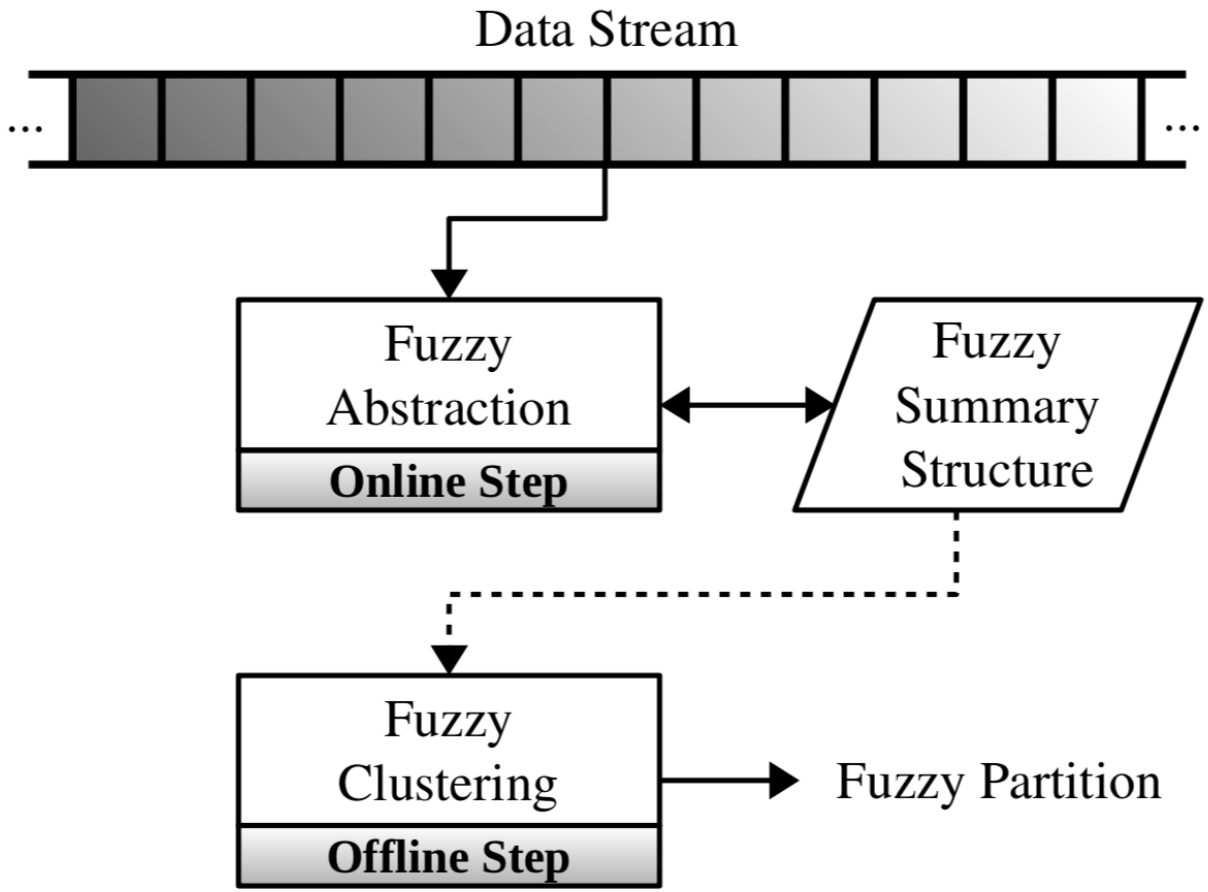

- Первый этап — микрокластезация (d-FuzzyStreram)
- Второй этап — макрокластеризация (Weighted Fuzzy C-Means)

Определения

Нечеткий микрокластер (Fuzzy Micro-Claster, FMiC) задается вектором

$$FMiC = (\overline{CF}, SSD, N, t, M)$$

- $\overline{CF}_i = \sum \mu_{ij} x_j$ — линейная взвешенная сумма наблюдений
- $SSD_i = \sum \mu_{ij}^m d(x_j, c_i)^2$ — квадратичная взвешенная сумма расстояний до наблюдений
- N_i — количество наблюдений
- t_i — дата последнего наблюдения
- $M_i = \sum_{x_j \in C_i} \mu_{ij}$ — сумма степеней принадлежности

Важные свойства: **инкрементность**, **аддитивность**

Определения

Тогда можно выразить

- $c = \overline{CF}/M$ — центроид микрокластера
- $dp = \sqrt{\frac{SSD}{N}}$ — нечеткое рассеивание (fuzzy dispersion), отражает радиус микрокластера
- $FR_{ij} = \frac{dp_i + dp_j}{d(c_i, c_j)}$ — матрица близости микрокластеров i и j. Чем больше значение, тем ближе микрокластеры
- $\tau \in [0, +\infty]$ — пороговое значение близости, при котором кластеры i и j объединяются в один. При $\tau < 1$ границы кластеров не пересекаются

Алгоритм d-FuzzyStream

Входные параметры: *minFMiC*, *maxFMiC* — минимальное и максимальное количество микрокластеров, τ — порог объединения микрокластеров, m — коэффициент размытия

1. Пока количество микрокластеров меньше минимального, создаем новые микрокластеры под каждое наблюдение
2. Если новое наблюдение попадает в радиус хотя бы одного микрокластера, то оно инкрементируется в параметры этих микрокластеров со степенью принадлежности

$$\mu_{ik} = 1 / \sum_j \left(\frac{d(x_k, v_i)^2}{d(x_k, v_j)^2} \right)^{\frac{1}{m-1}}$$

3. Если новое наблюдение не попадает в радиус микрокластера, то создаем под него новый микрокластер
4. При превышении максимального количества кластеров удаляется самый старый
5. При превышении порога близости кластеры объединяются

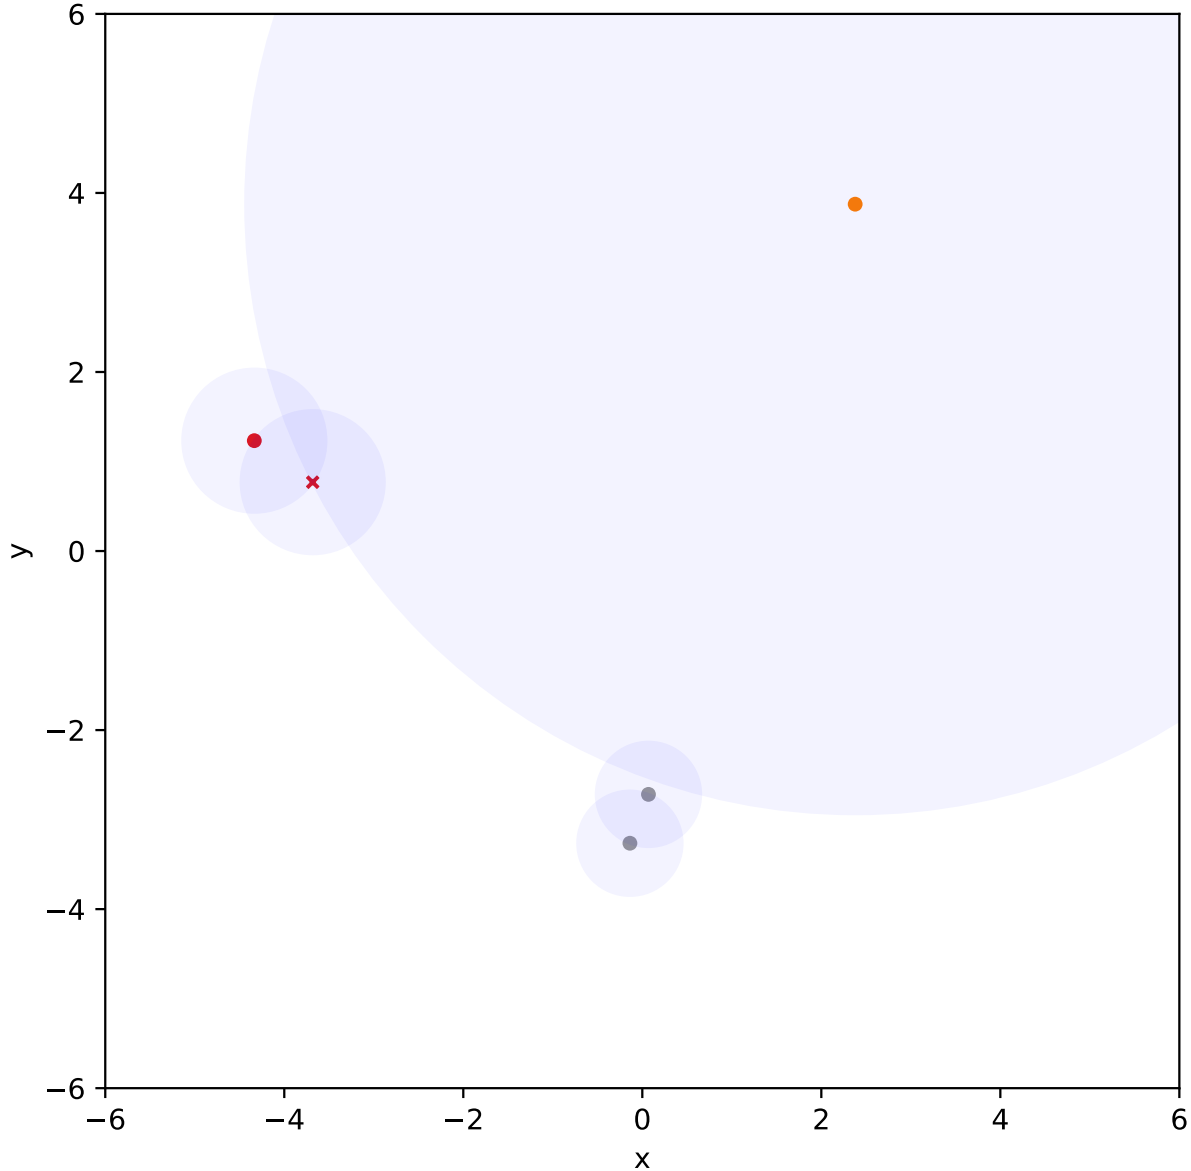
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

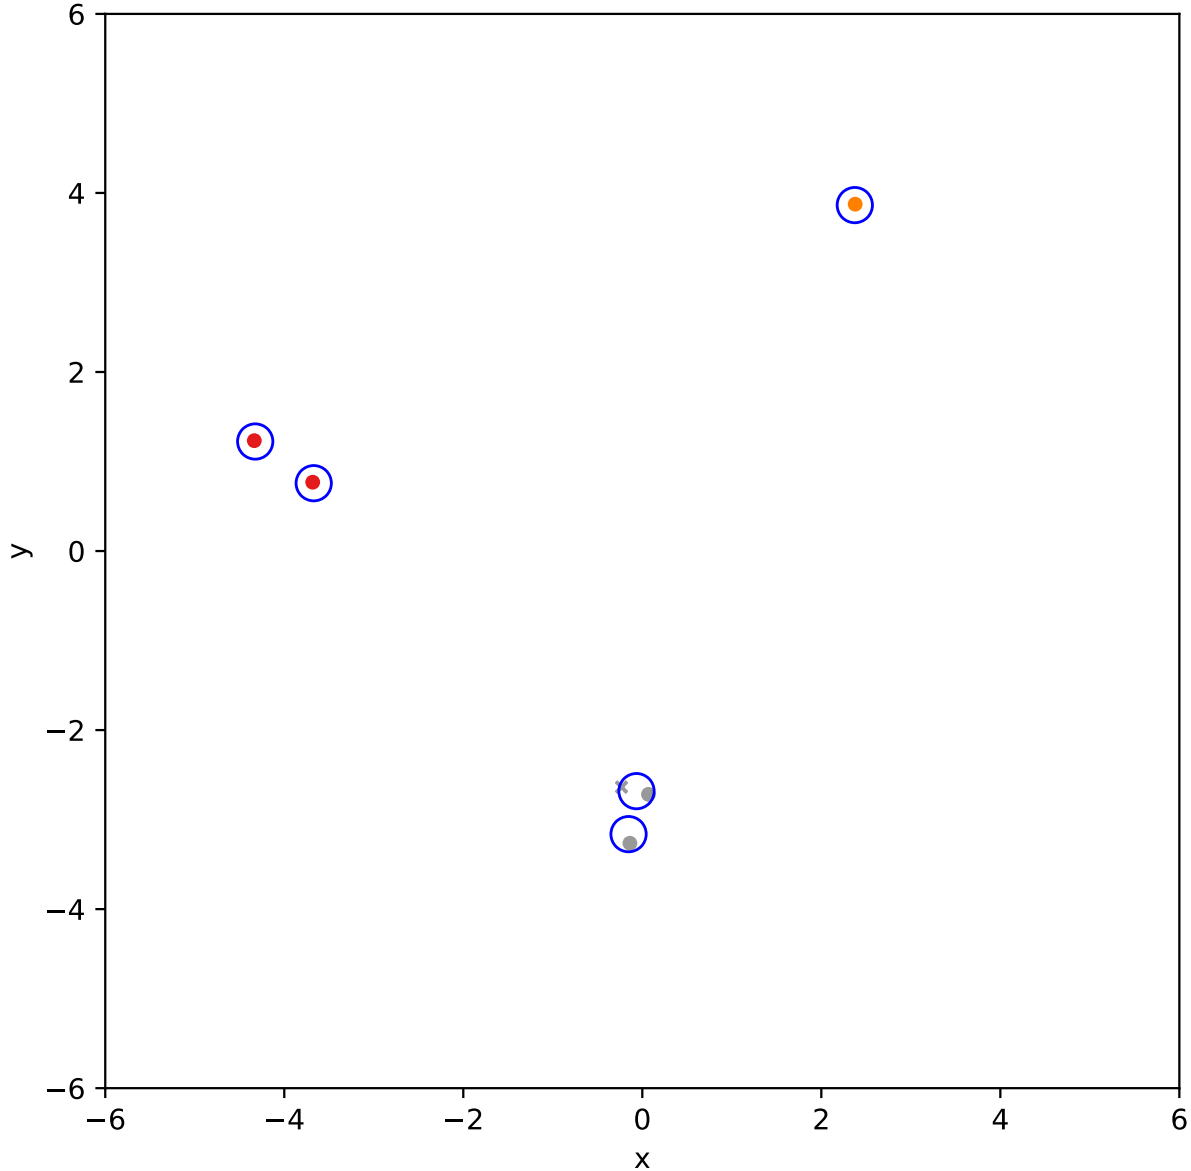
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

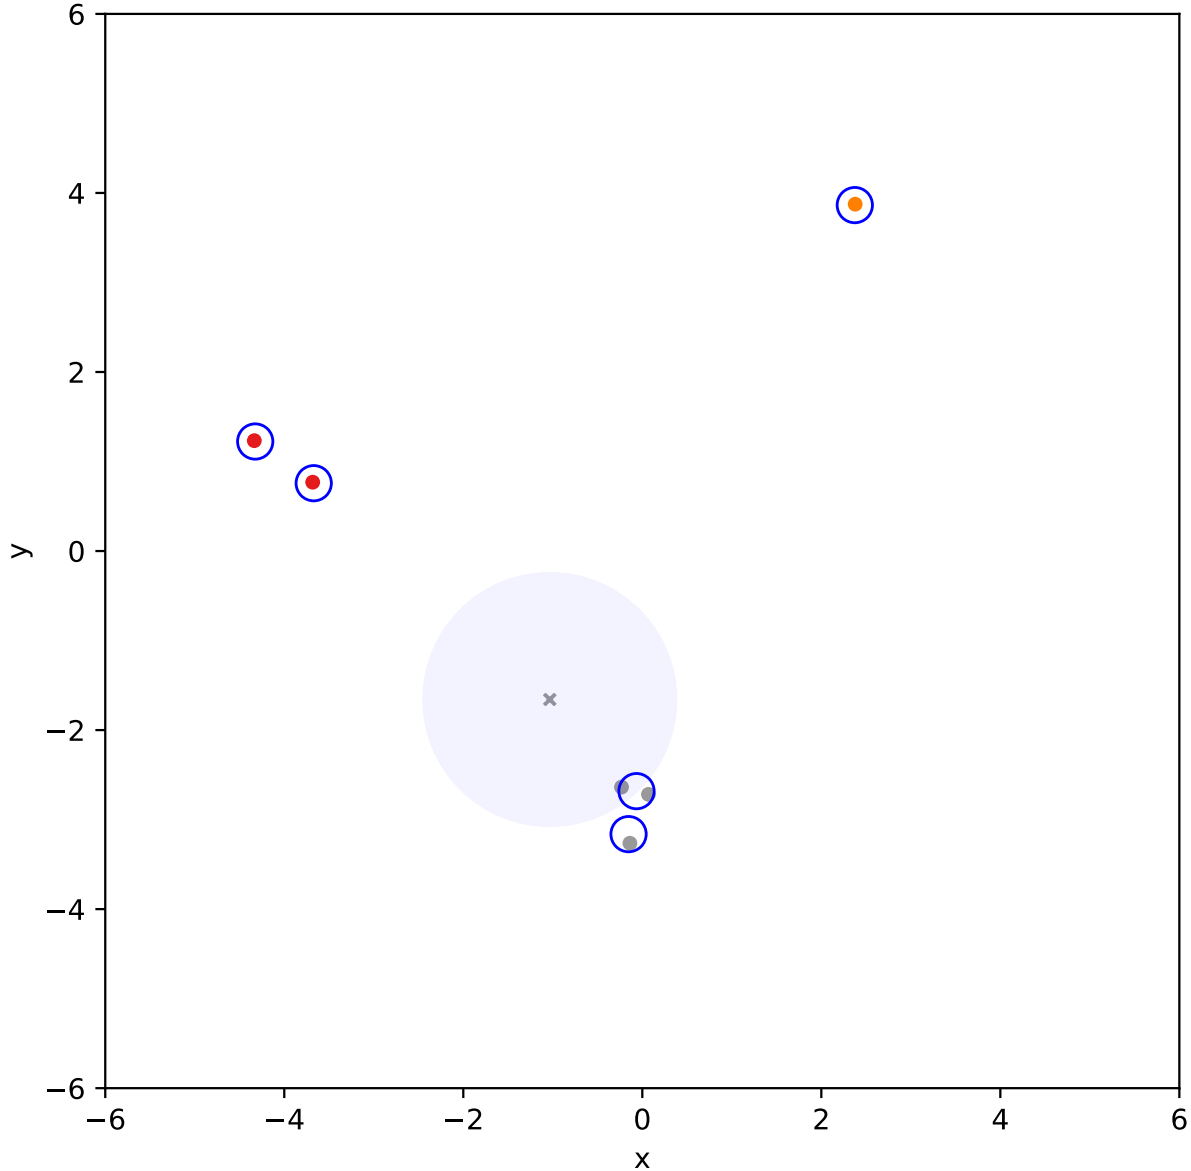
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

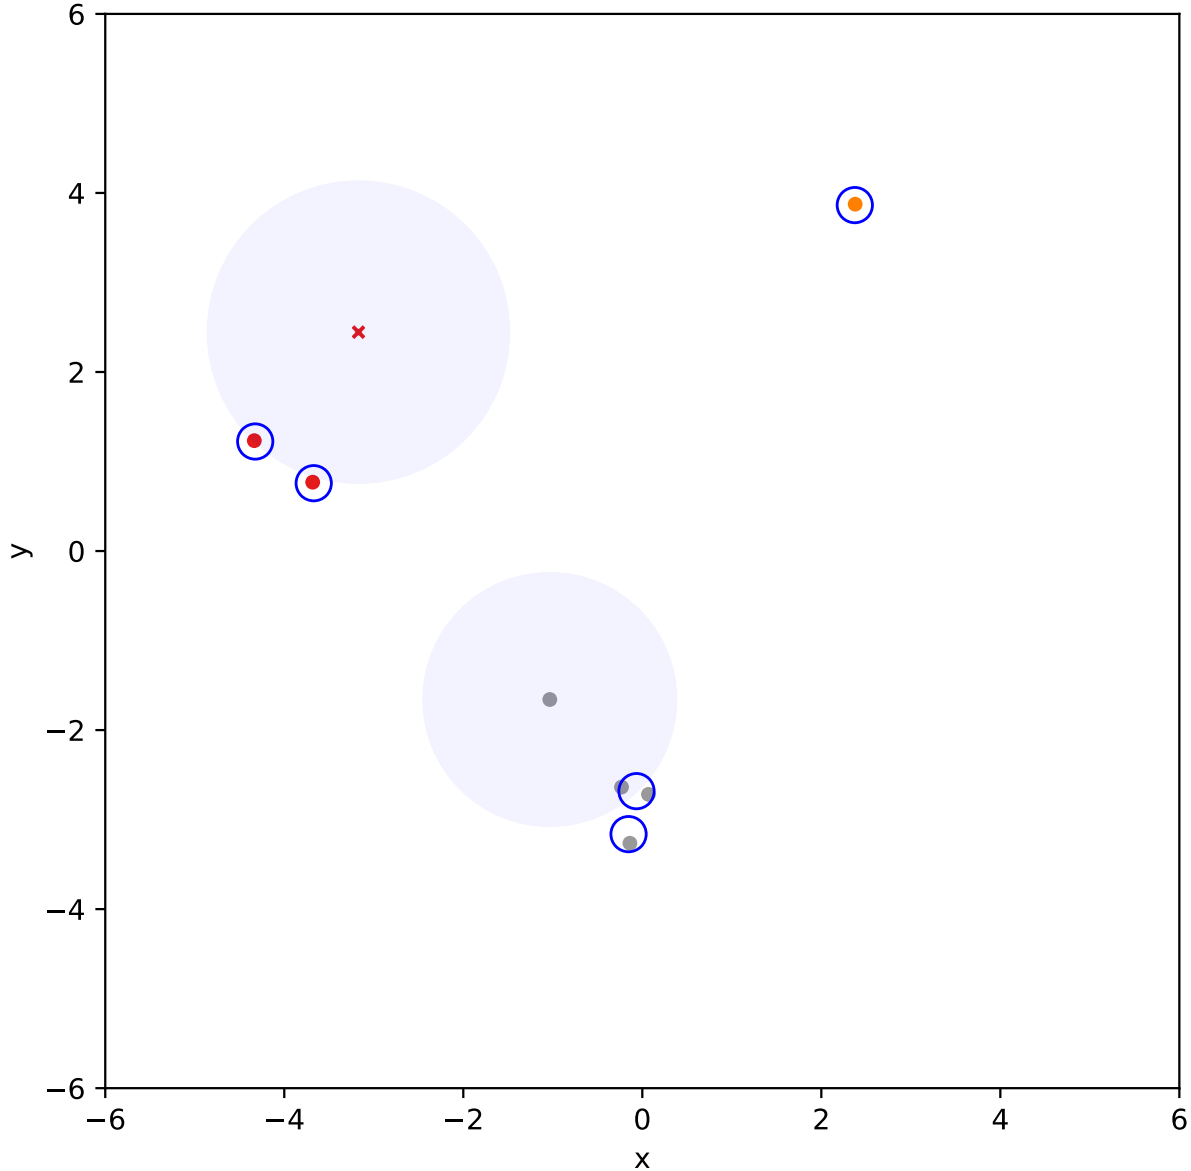
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

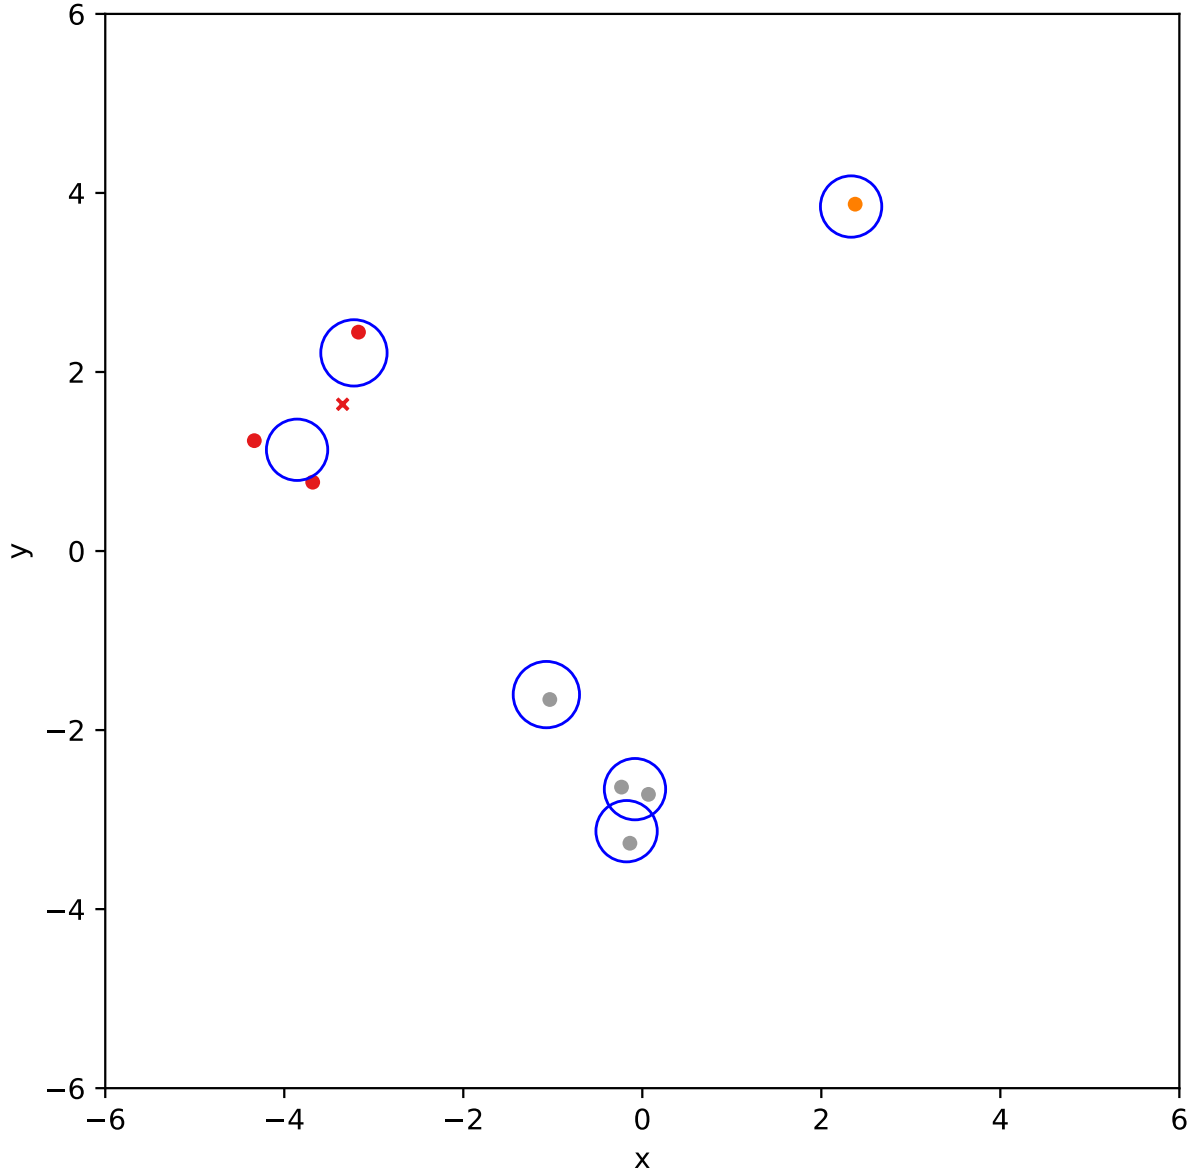
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

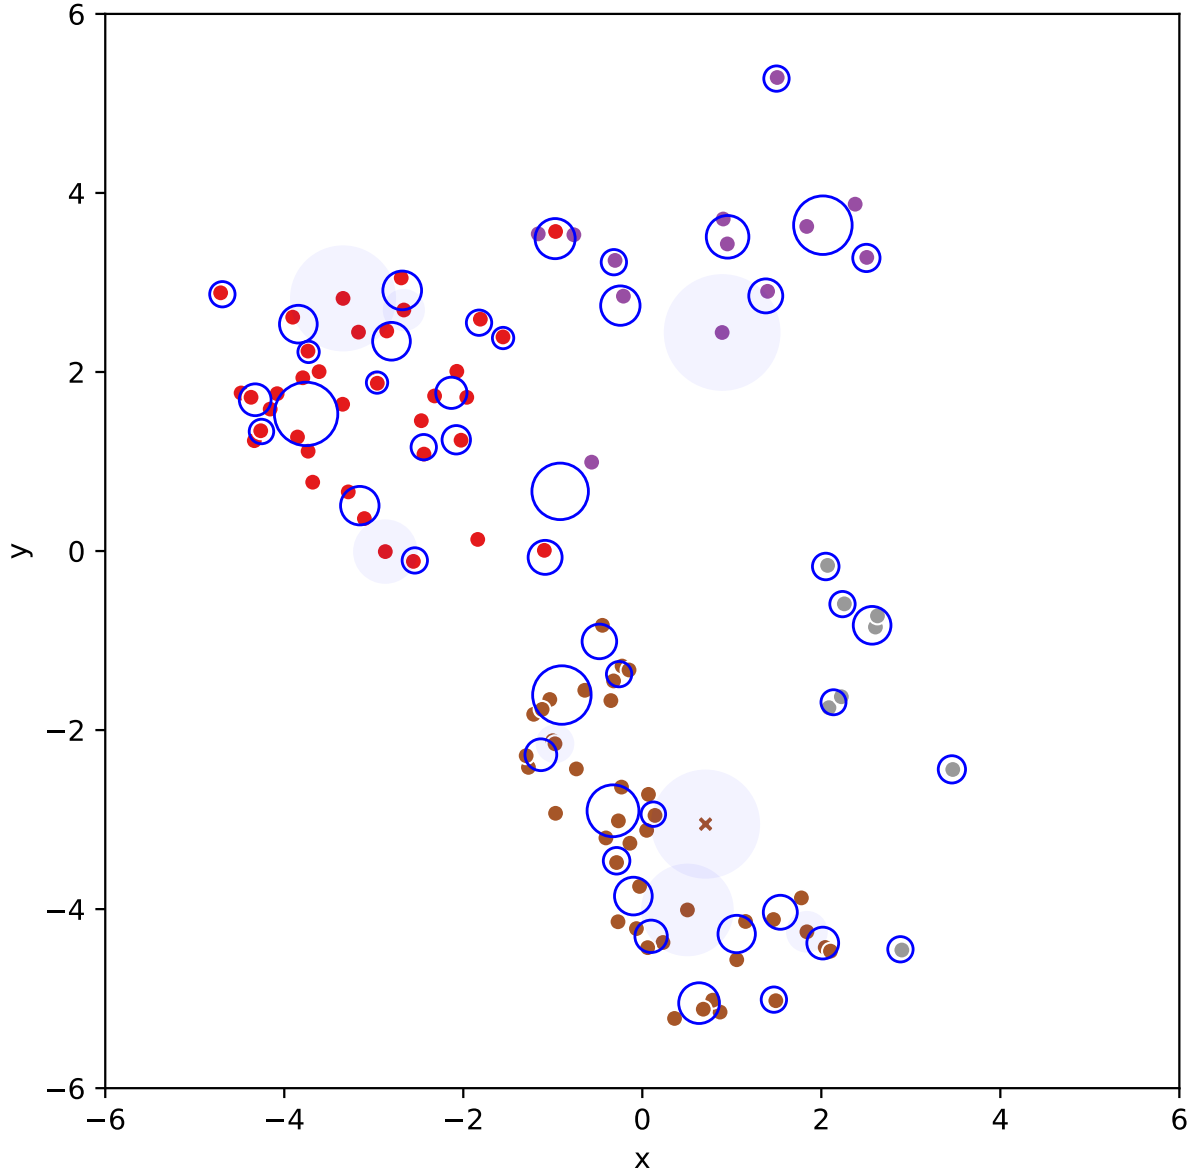
6
4
2
0
−2
−4
−6
y
−6
−4
−2
0
2
4
6
x

Датасеты для тестирования

- Сгенерированные 10000 наблюдений (3 временных среза)

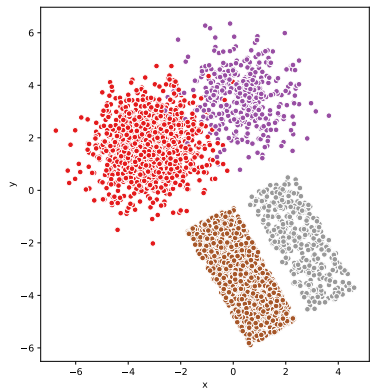
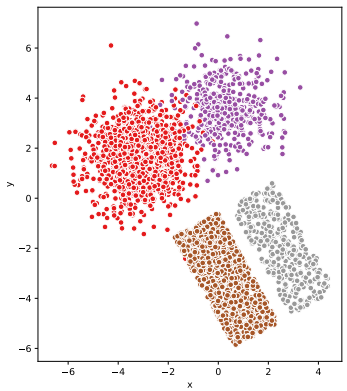
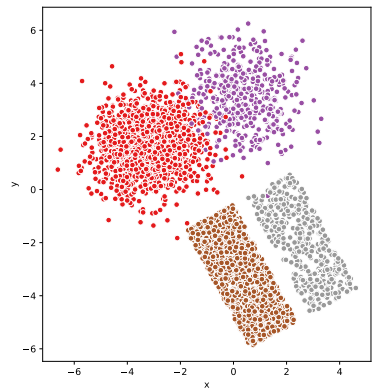

- Сгенерированные 11000 наблюдений (3 временных среза)

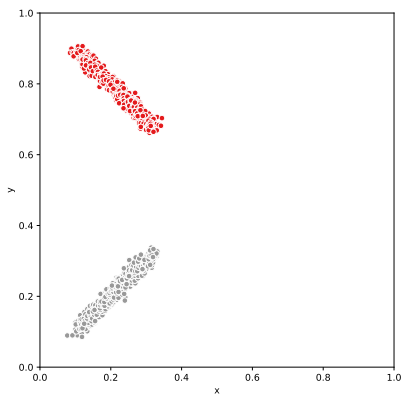
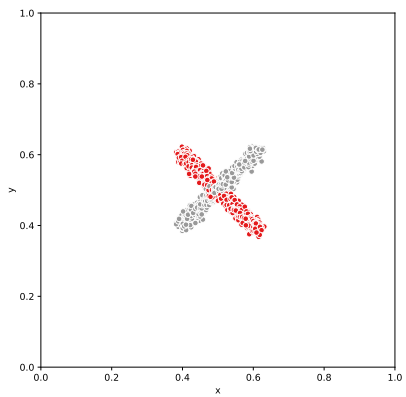
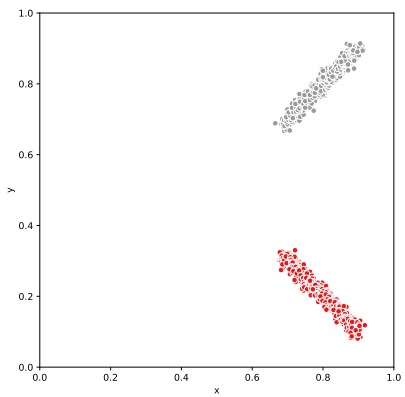

Метрики качества

- *Creations* — количество созданных микрокластеров
- *Removals* — количество удаленных микрокластеров
- *Absorptions* — количество попаданий в радиус микрокластера
- *Merges* — количество объединений микрокластеров
- $Purity = \frac{1}{N} \sum_i \max_j |C_i \cap T_j|$ — мера «чистоты» кластеризации, где T_j — размеченный заранее класс наблюдения

Результаты тестирования

Датасет #1 (1000 - 2000 - 3000)

#	purity	creations	removals	merges	absorptions	seconds
0	0.194	523	91	332	623	29
1	0.129	824	451	274	182	75
2	0.127	821	387	335	295	68
Среднее	**0.15**	**722.67**	**309.67**	**313.67**	**366.67**	**57.33**

Датасет #2 (1000 - 2000 - 3000)

#	purity	creations	removals	merges	absorptions	seconds
0	0.194	523	91	332	623	29
1	0.129	824	451	274	182	75
2	0.127	821	387	335	295	68
Среднее	**0.15**	**722.67**	**309.67**	**313.67**	**366.67**	**57.33**

Литература

- A Framework for Clustering Evolving Data Streams, 2003, Charu C. Aggarwal, Jiawei Han, Jianyong Wang, Philip S. Yu
- FuzzStream: Fuzzy Data Stream Clustering Based on the Online-Offline Framework, 2017, Priscilla de Abreu Lopes and Heloisa de Arruda Camargo
- d-FuzzStream: A Dispersion-Based Fuzzy Data Stream Clustering, 2018, Leonardo Schick, Priscilla de Abreu Lopes and Heloisa de Arruda Camargo
- Merging Clusters in Summary Structures for Data Stream Mining based on Fuzzy Similarity Measures, 2019, Leonardo Schick, Priscilla de Abreu Lopes and Heloisa A. Camargo